

**UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE**  
**DISCIPLINA: REDES NEURAIIS - DEEP LEARNING**  
**Iª LISTA DE EXERCÍCIO) - 2021.2**

**Data de entrega da lista com apresentação: 21/09/2021**

Objetivos da lista: consolidar os conceitos de: redes neurais, processos de aprendizagem de máquinas e estimular uma revisão dos conceitos de álgebra linear, cálculo de múltiplas variáveis, métodos de otimização e os fundamentos de aprendizagem de máquinas.

1-) Considere o problema de estimativa da matriz de covariância de uma dada distribuição

de vetores aleatórios dados por  $\mathbf{x}_1 = \begin{bmatrix} 7 \\ 3 \\ 9 \end{bmatrix}, \mathbf{x}_2 = \begin{bmatrix} 4 \\ 6 \\ 11 \end{bmatrix}, \mathbf{x}_3 = \begin{bmatrix} 4 \\ 2 \\ 5 \end{bmatrix}, \mathbf{x}_4 = \begin{bmatrix} 5 \\ 5 \\ 7 \end{bmatrix}$ . Estime o vetor média (média amostral) e a matriz de covariância amostral  $\mathbf{S} = \{s_{ij}\}$  assumindo que a matriz é

simétrica. Observando que a média amostral é dada por  $\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$  e a variância amostral

é dada por  $s_{ij} = \frac{\sum_{l=1}^N (x_{il} - \hat{\mu}_i)(x_{jl} - \hat{\mu}_j)}{N-1}$ . Calcule também a partir da matriz de covariância

obtida:

a-) Os autovalores e autovetores da matriz e mostre a forma fatorada da matriz isto é  $\mathbf{S} = \mathbf{V}^{-1} \mathbf{D} \mathbf{V}$ . Onde  $\mathbf{D}$  é a matriz diagonal dos autovalores e  $\mathbf{V}$  é a matriz dos autovetores correspondentes.

b-) Calcule fazendo uso da forma fatorada  $\mathbf{S}^4$

c-) Calcule a norma Euclidiana da matriz e compare com seu valor estimado pelo traço da matriz.

d-) Calcule a distancia Euclidiana dos vetores aleatórios.

e-) Calcule a distancia de Mahalanobis dos vetores aleatórios e compare com a distancia Euclidiana

2) Considere a função  $E(\mathbf{w})$  onde  $\mathbf{w} = [w_1, w_2, \dots, w_n]^t$  é um vetor com múltiplas variáveis.

Usando a expansão em série de Taylor a função pode ser expressa como  $E(\mathbf{w}(n) + \Delta \mathbf{w}(n)) = E(\mathbf{w}(n)) + \mathbf{g}^t(\mathbf{w}(n)) \Delta \mathbf{w}(n) + \frac{1}{2} \Delta \mathbf{w}^t(n) \mathbf{H}(\mathbf{w}(n)) \Delta \mathbf{w}(n) + O(\|\Delta \mathbf{w}\|^3)$ , on-

de  $\mathbf{g}(\mathbf{w}(n))$  é o vetor gradiente local definido por  $\mathbf{g}(\mathbf{w}) = \frac{\partial E(\mathbf{w})}{\partial \mathbf{w}}$  e  $\mathbf{H}(\mathbf{w})$  é matriz Hessiana,

definida por  $\mathbf{H}(\mathbf{w}) = \frac{\partial^2 E(\mathbf{w})}{\partial \mathbf{w}^2}$ .

Demonstre:

a-) que o método do gradiente da descida mais íngreme é dado por

$$\mathbf{w}(n+1) = \mathbf{w}(n) - \eta \mathbf{g}(\mathbf{w}(n))$$

b-) que o método de Newton é dado por

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \mathbf{H}^{-1}(\mathbf{w}(n))\mathbf{g}(\mathbf{w}(n))$$

e indique que condição a matriz Hessiana  $\mathbf{H}(\mathbf{w}) = \frac{\partial^2 E(\mathbf{w})}{\partial \mathbf{w}^2}$  precisa atender para o método poder ser aplicado.

3-) Considere a função Rosenbrock com duas variáveis

$f(x, y) = (1-x)^2 + 100(y-x^2)^2$  que é uma função comumente utilizada para avaliar o desempenho de um algoritmo de otimização. Seu ponto de mínimo é (1,1). Utilize os métodos do gradiente da descida mais íngreme assim como o método de Newton para solução numérica do cálculo do mínimo. Avalie o desempenho de cada um dos métodos.

4-) Considere o problema de otimização com restrições:

$$\begin{aligned} \text{minimize } f(\mathbf{x}) &= 2x_1^2 - 2x_1x_2 + 4x_2^2 + 5 \\ \text{sujeito a:} \\ g_1(x_1, x_2) &= x_1 + x_2 = 0 \end{aligned}$$

formule o problema usando o funcional de Lagrange e calcule os valores  $(x_1^*, x_2^*)$  para mínimo da função.

5-) Apresente um estudo sobre o método do gradiente estocástico (SGM).

6-) O modelo de neurônio artificial de Mc-Culloch-Pitts faz uso da função de ativação para resposta do neurônio artificial. As funções sigmoíde (ou função logística) e tangente hiperbólica (tangsigmoíde) são normalmente utilizadas nas redes neurais perceptrons de múltiplas camadas tradicionais. A função ReLu (retificador linear) é normalmente utilizadas em redes Deep Learning. Segue abaixo as expressões matemáticas de cada uma:

$$\text{a-) } \varphi(v) = \frac{1}{1 + \exp(-av)} \text{ (sigmoíde); b-) } \varphi(v) = \frac{1 - \exp(-av)}{1 + \exp(-av)} = \tanh\left(\frac{av}{2}\right) \text{ (tangsigmoíde) ;}$$

$$\text{c-) } \varphi(v) = \max(0, v) \text{ (Re-Lu).}$$

i) Faça uma análise comparativa de cada uma destas funções apresentando de forma gráfica a variação da função e da sua derivada com relação a v ( potencial de ativação)

$$\text{ii) Mostre que } \varphi'(v) = \frac{d\varphi(v)}{dv} = a\varphi(v)[1 - \varphi(v)] \text{ para função sigmoíde.}$$

$$\text{iii) Mostre que } \varphi'(v) = \frac{d\varphi(v)}{dv} = \frac{a}{2}[1 - \varphi^2(v)] \text{ para função tangsigmoíde.}$$

7-) Dada a função  $E(n)$  que corresponde a função custo com base no erro ao quadrado, calculada na saída do neurônio  $j$  de uma rede neural perceptron de múltiplas camadas

$$E(n) = \frac{1}{2} e_j^2(n) \quad \text{com}$$

$$e_j(n) = d_j(n) - y_j(n) \quad ,$$

$$y_j(n) = \varphi(v_j(n)); \quad v_j(n) = \sum_{i=0}^m w_{ji}(n) y_i(n)$$

i) Demonstre que  $\frac{\partial E(n)}{\partial w_{ji}(n)} = -e_j(n) \varphi'(v_j(n)) y_i(n)$

ii) Considerando as funções de ativação da questão anterior apresente a expressão

$$\frac{\partial E(n)}{\partial w_{ji}(n)} = -e_j(n) \varphi'(v_j(n)) y_i(n)$$

8-) O método da máxima verossimilhança (Max-Likelihood) aplicado na determinação de parâmetros desconhecidos de um modelo de distribuição de probabilidades. O método é bastante utilizado para o desenvolvimento de algoritmos de aprendizagem de máquinas em particular em redes neurais. O problema considerado nesta questão envolve o modelo probabilístico de um comitê de redes especialistas e uma rede que indica qual das redes especialista é a mais adequada para processar uma determinada entrada. O problema consiste em determinar os parâmetros  $\mathbf{w}$  das redes especialistas e  $\mathbf{a}$  da rede que decide qual a rede especialista deve processar uma determinada entrada. O modelo probabilístico é denominado de modelo de misturas de gaussianas, dado por

$$f(\mathbf{d} | \mathbf{x}; \mathbf{w}, \mathbf{a}) = \sum_{i=1}^K g_i f(\mathbf{d} | \mathbf{x}; \mathbf{i}; \mathbf{w}, \mathbf{a}) = \frac{1}{(2\pi)^{q/2}} \sum_{i=1}^K g_i \exp\left(-\frac{1}{2} \|\mathbf{d} - \mathbf{y}_i\|^2\right)$$

$$y_i^{(m)} = \mathbf{x}^t \mathbf{w}_i^{(m)}, \quad \begin{cases} i = 1, 2, \dots, K \\ m = 1, 2, \dots, q \end{cases}$$

$$g_i = \frac{\exp(u_i)}{\sum_{j=1}^K \exp(u_j)} \quad 0 \leq g_i \leq 1 \quad \sum_{i=1}^K g_i = 1$$

$$u_i = \mathbf{x}^t \mathbf{a}$$

sendo  $\mathbf{d}$  vetor de resposta desejada,  $\mathbf{y}_i$  vetor de saída de cada rede especialista,  $\mathbf{w}_i$  o vetor de pesos de cada rede especialista,  $\mathbf{a}$  o vetor de pesos da rede decisora,  $q$  a dimensão do vetor de entrada e do vetor de pesos e  $K$  o número de redes especialistas. A função

$$g_i = \frac{\exp(u_i)}{\sum_{j=1}^K \exp(u_j)}$$

é conhecida como função softmax e corresponde neste problema a probabilidade a priori da rede  $i$  ser escolhida. A função  $h_i$  definida abaixo corresponde a probabilidade da posteriori da rede ser escolhida.

Definindo função log de verossimilhança como

$$l(\mathbf{w}, \mathbf{a}) = \ln \sum_{i=1}^K g_i \exp(-\frac{1}{2} \|\mathbf{d} - \mathbf{y}_i\|^2)$$

o problema consiste em com relação aos parâmetros  $\mathbf{w}$  e  $\mathbf{a}$ . Fazendo uso do método do gradiente da descida mais íngreme para determinação  $\max l(\mathbf{w}, \mathbf{a})$ .

mostre que

$$\mathbf{w}_i^{(m)}(n+1) = \mathbf{w}_i^{(m)}(n) + \eta h_i(n) e_i^{(m)}(n) \mathbf{x}$$

$$\mathbf{a}_i(n+1) = \mathbf{a}_i(n) + \mu [h_i(n) - g_i(n)]$$

$$e_i^{(m)} = d^{(m)} - y_i^{(m)}(n)$$

$$h_i(n) = \frac{g_i(n) \exp(-\frac{1}{2} \|\mathbf{d} - \mathbf{y}_i(n)\|^2)}{\sum_{j=1}^K g_j(n) \exp(-\frac{1}{2} \|\mathbf{d} - \mathbf{y}_j(n)\|^2)} \quad 1 \leq h_i(n) \leq 1 \quad \sum_{i=1}^K h_i(n) = 1$$

## 9-) Implementações Computacionais de Redes Neurais.

Para cada uma das aplicações abaixo apresente a curva do erro de treinamento e de validação:

9.1-) Defina a estrutura de uma rede perceptron de múltiplas camadas para aproximar as funções abaixo. Defina o conjunto de treinamento e de validação. Compare para os itens b e c a aproximação da função obtida pela rede neural com as curvas exatas. Apresente para cada caso a curva do erro médio de treinamento com relação ao número de épocas e a curva do erro médio com o conjunto de validação.

a) a função lógica  $f(x_1, x_2, x_3) = x_1 \oplus x_2 \oplus x_3$

b) a função real

$$f(x_1, x_2) = \left( \frac{\cos(2\pi x_1)}{1 - (4x_1)^2} \operatorname{sen}(\pi x_1) / \pi x_1 \right) \left( \frac{\cos(2\pi x_2)}{1 - (4x_2)^2} \operatorname{sen}(\pi x_2) / \pi x_2 \right) \quad -4\pi \leq x_1 \leq 4\pi \quad -4\pi \leq x_2 \leq 4\pi$$

9.2-) Utilize a rede neural perceptron de múltiplas camadas para fazer a predição de um passo ( $x^{(n+1)}$ ) da série temporal  $x(n) = 1 + \cos(n + \cos^2(n))$ . Avalie o desempenho mostrando a curva a série temporal, a curva de predição e a curva do erro de predição.

9.3-) Considere o problema de classificação de padrões bidimensionais constituído neste caso de 2 padrões. A distribuição dos padrões tem como base um quadrado centrado na origem interceptando os eixos nos pontos +1 e -1 de cada eixo. Os pontos +1 e -1 de cada eixo são centros de quatro semicírculos que se interceptam no interior do quadrado originando uma classe e a outra classe corresponde às regiões de não interseção. Após gerar aleatoriamente os dados que venham formar estas distribuições de dados, selecione um conjunto de treinamento e um conjunto de validação. Solucione este problema considerando uma rede perceptron de múltiplas camadas

## 10 - Trabalho::

Apresente um estudo com uma análise comparativa dos algoritmos: **AdaGrad, RMSProp e Adam, que tem como base o** método do gradiente estocástico (SGM) e são utilizados no processo de aprendizagem de redes neurais deep learning.

Data de entrega: 21/09/2021

A entrega e apresentação dos trabalhos correspondem a um processo de avaliação. Portanto a presença é obrigatória.

O trabalho e a lista podem ser feitos em grupo de até três componentes.

Na apresentação os componentes poderão ser submetidos a questionamentos sobre a solução da lista e o desenvolvimento dos trabalhos.

